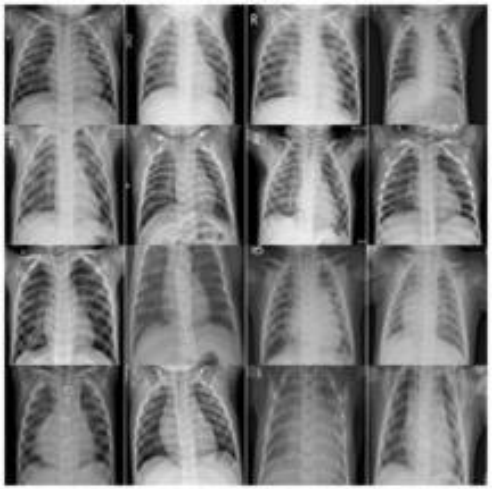
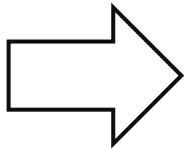
拡散モデルを用いた敵対的摂動除去による医用画像分類システム防御

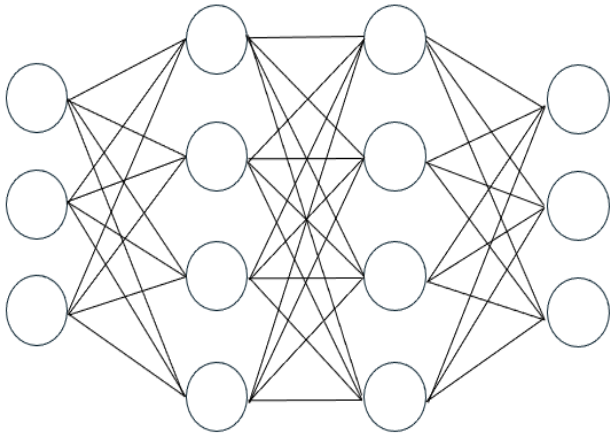
後藤良輔　竹本和広
九州工業大学 情報工学部 生命化学情報工学科

深層学習の発展

深層学習を用いた医用画像分類システムは
診断支援として広く活用されるようになっている







敵対的攻撃に脆弱

敵対的攻撃(Adversarial Attack)



元画像　　敵対的摂動　　敵対的画像

わずかな摂動で誤分類
重大な医療事故につながる

摂動の除去が必要

摂動の除去手法

これまでJPEG圧縮、GAN、VAEなどの摂動の除去方法が考えられてきた

JPEG圧縮

GAN
(Generative Adversarial Networks)

VAE
(Variational Auto Encoder)

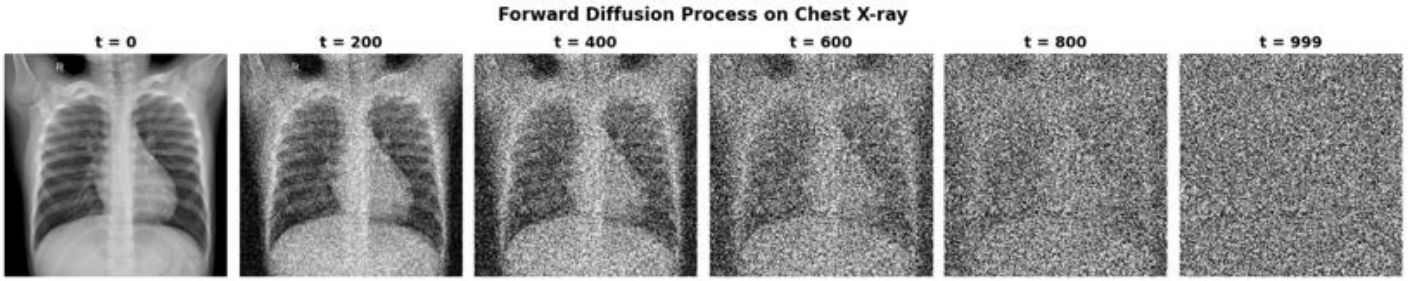
JPEG圧縮：画像の圧縮過程で摂動除去

GAN、VAE：生成モデルによって、元の摂動なし画像を再構成して摂動除去

拡散モデルとは

拡散モデルは、画像にノイズを段階的に加え、逆にノイズを取り除く過程を学習することで、高品質な生成やノイズ除去を可能にするモデル。

拡散過程：徐々にノイズを付加する



逆拡散過程：徐々にノイズを除去し元の画像を復元する

九州工業大学　竹本研究室　後藤

先行研究

DDPM: Denoising Diffusion Probabilistic Models

拡散モデルを用いて敵対的摂動を除去し、分類精度を回復させる手法



一般画像では有効であるが医用画像での応用はまだ少ない

[Nie et al., arXiv:2205.07460, 2022]

本研究の目的

拡散モデルによる敵対的摂動除去
の有効性を、医用画像分類で検証し
既存防御手法と比較することで明らかにする

実験設定

各摂動除去手法を敵対的画像に対して適用し
防御後の分類精度でそれぞれの防御性能を評価する

① 防御処理	② 分類	③ 評価
敵対的画像に 各摂動除去手法を 適用する	摂動除去後の画像 を用いて分類器で 分類行う	各摂動除去手法での 分類精度を比較して 評価を行う



敵対的画像

①摂動除去



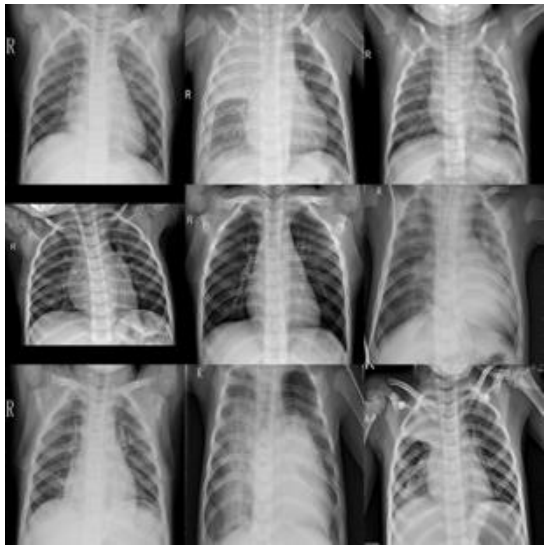
摂動除去後の画像

②分類

九州工業大学　竹本研究室　後藤

データセット

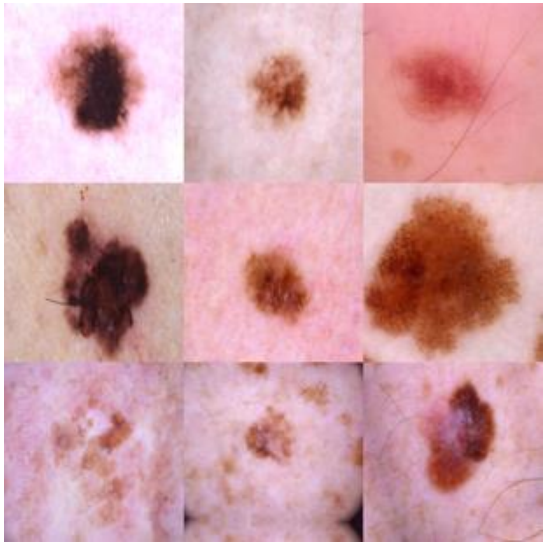
ChestXray



[胸部X線画像]

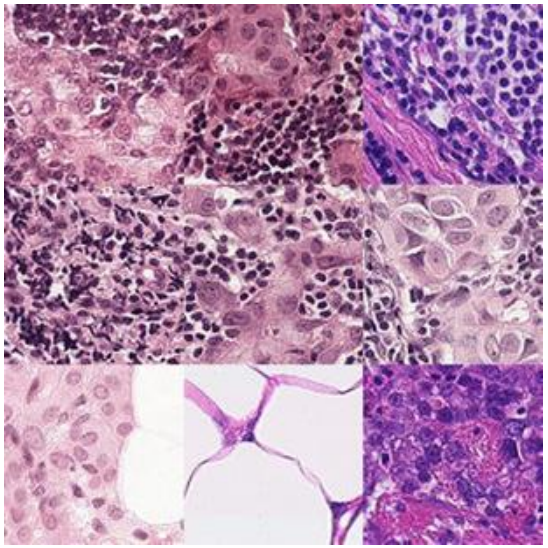
肺炎 or 非肺炎

DermMel



[皮膚病変画像]

PCam



[がん病理画像]

がん or 非がん

九州工業大学　竹本研究室　後藤

分類器と攻撃手法

分類器

ResNet50 …… CNNベースの画像分類モデル

Vision Transformer (ViT) … Transformerベースの画像分類モデル

攻撃手法

FGSM …… モデルの勾配を利用し、1ステップで画像をわずかに変化させる単純な攻撃手法

PGD …… FGSMを複数回反復する強力な攻撃手法

AutoAttack …… 複数の攻撃を組み合わせた強力な攻撃手法

九州工業大学　竹本研究室　後藤

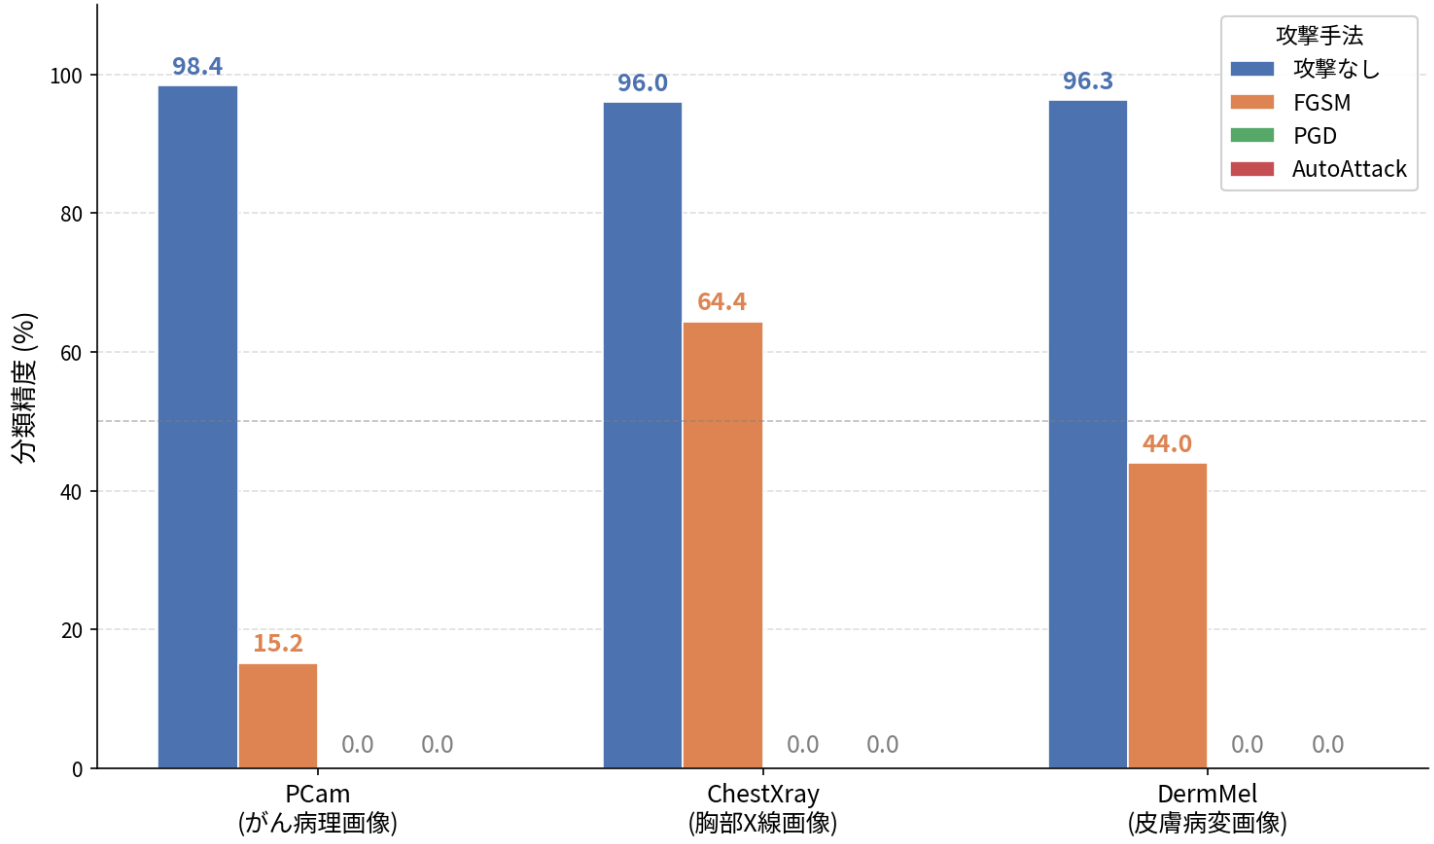
摂動除去手法

摂動除去手法	説明
JPEG圧縮	画像を圧縮して細かいノイズを削除
ImageNet 事前学習DDPM	一般画像で学習された拡散モデル
VAE	医用画像で学習したVAE
GAN	医用画像で学習したGAN
DDPM	医用画像で学習した拡散モデル

評価にはテストデータから訓練した分類器が
正しく分類した500サンプルを用いた

分類器の分類精度

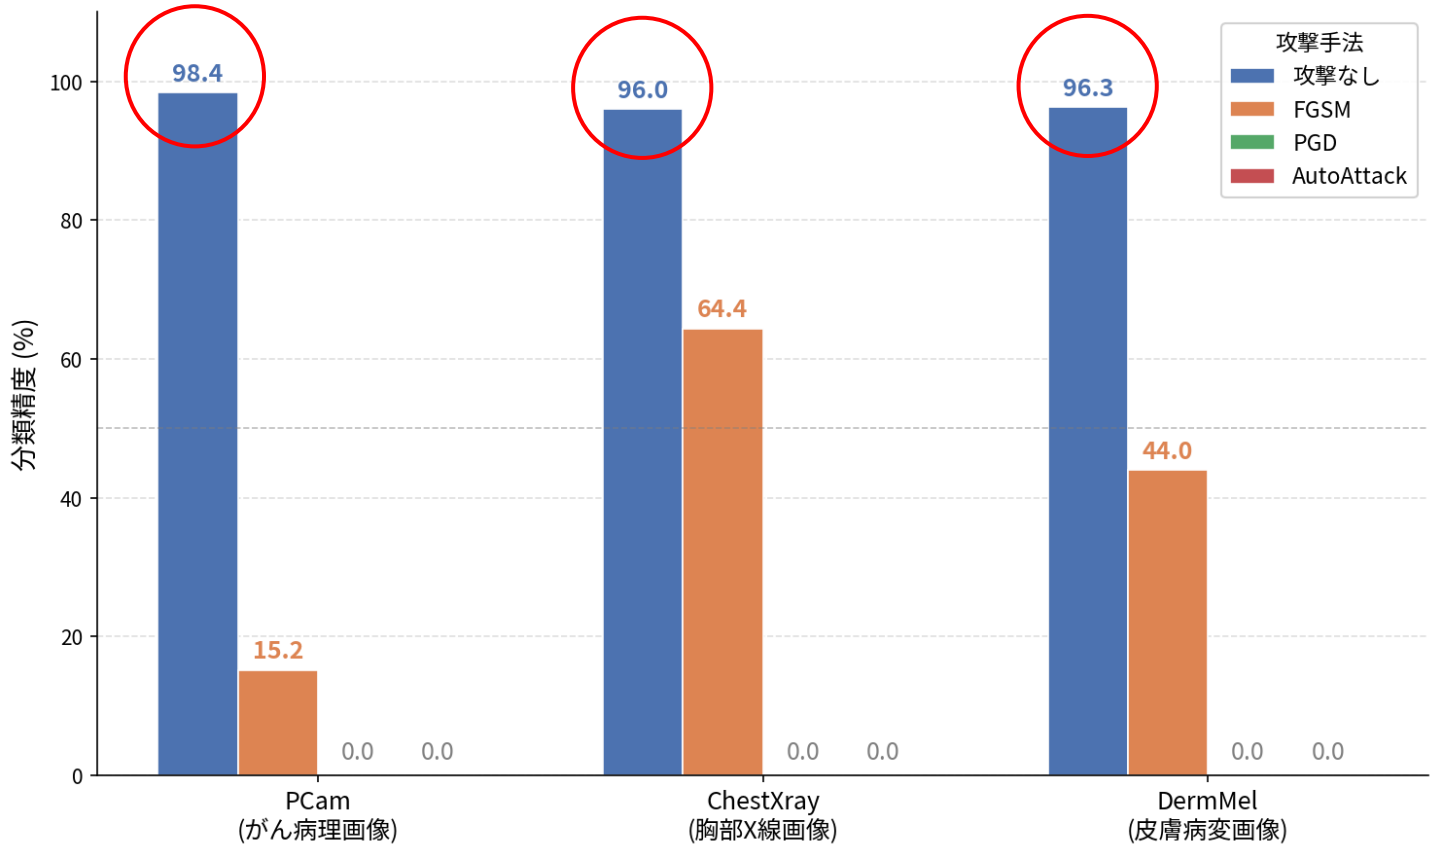
攻撃前は高い分類精度であったが、攻撃により精度が著しく低下した



九州工業大学　竹本研究室　後藤

分類器の分類精度

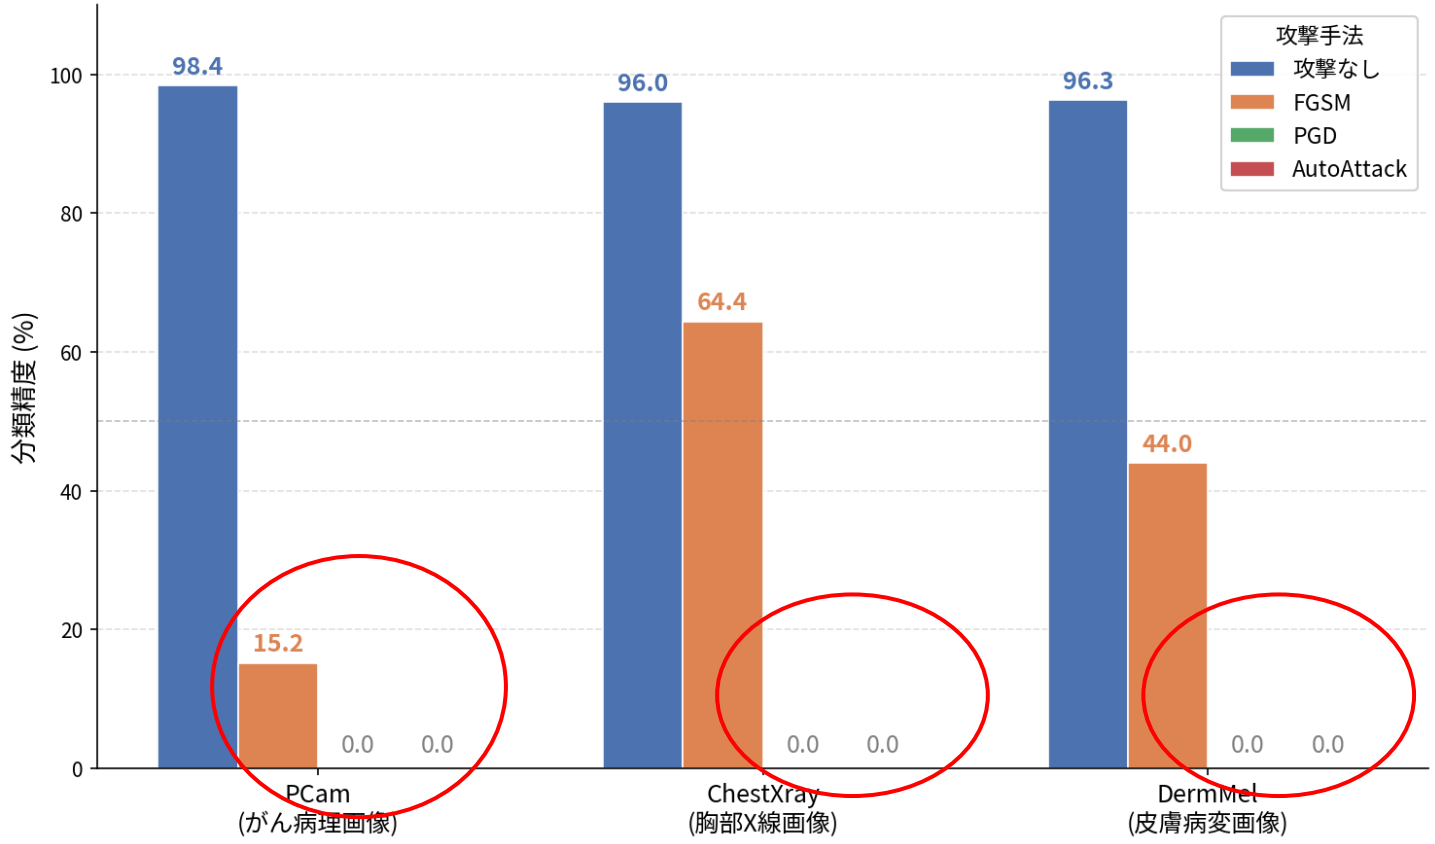
攻撃前は高い分類精度であったが、攻撃により精度が著しく低下した



九州工業大学　竹本研究室　後藤

分類器の分類精度

攻撃前は高い分類精度であったが、攻撃により精度が著しく低下した

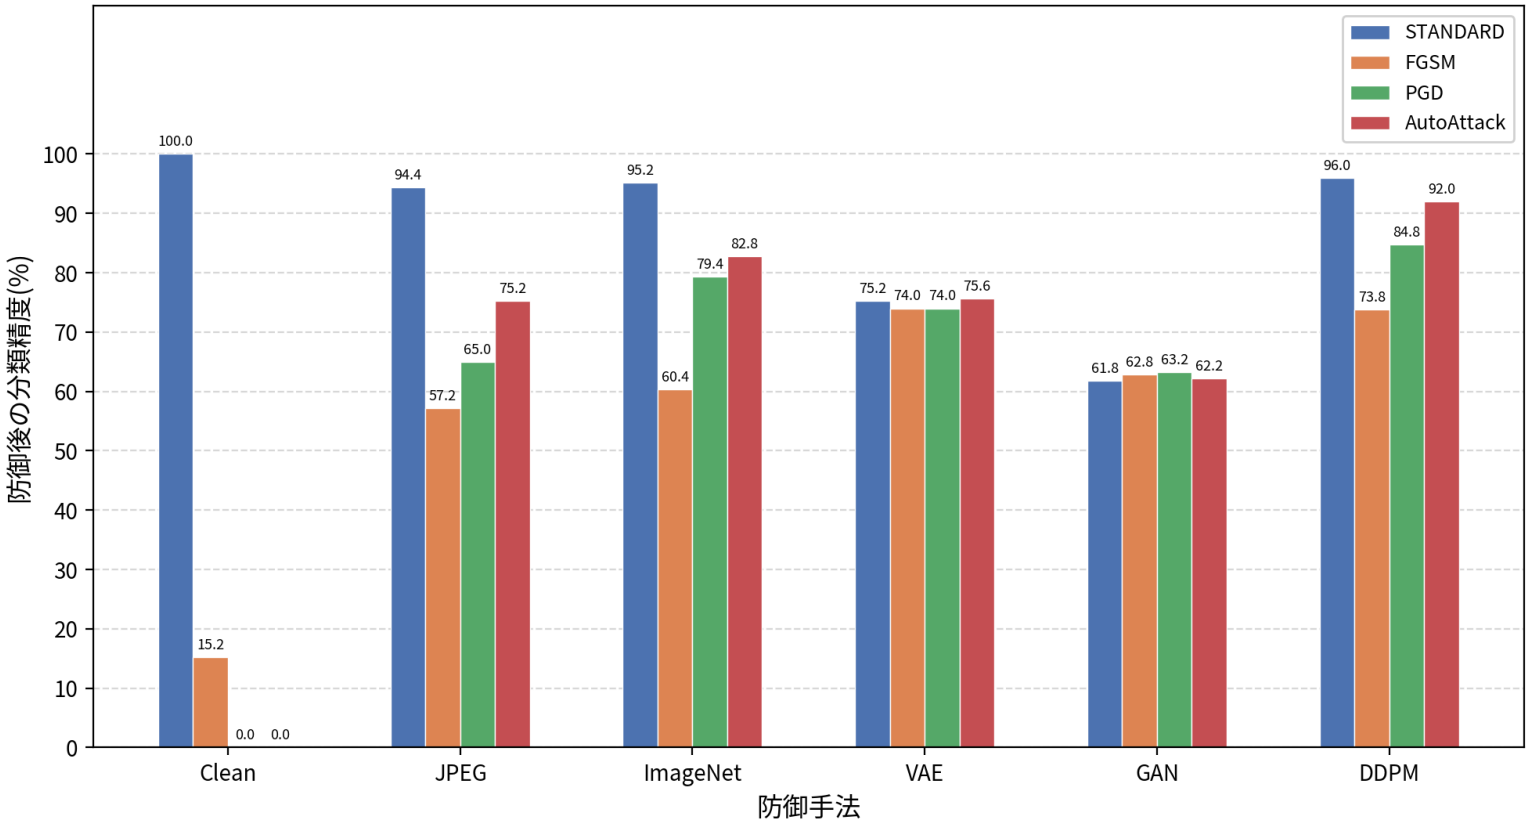


九州工業大学　竹本研究室　後藤

摂動除去後の分類結果

- **PCamデータセット**

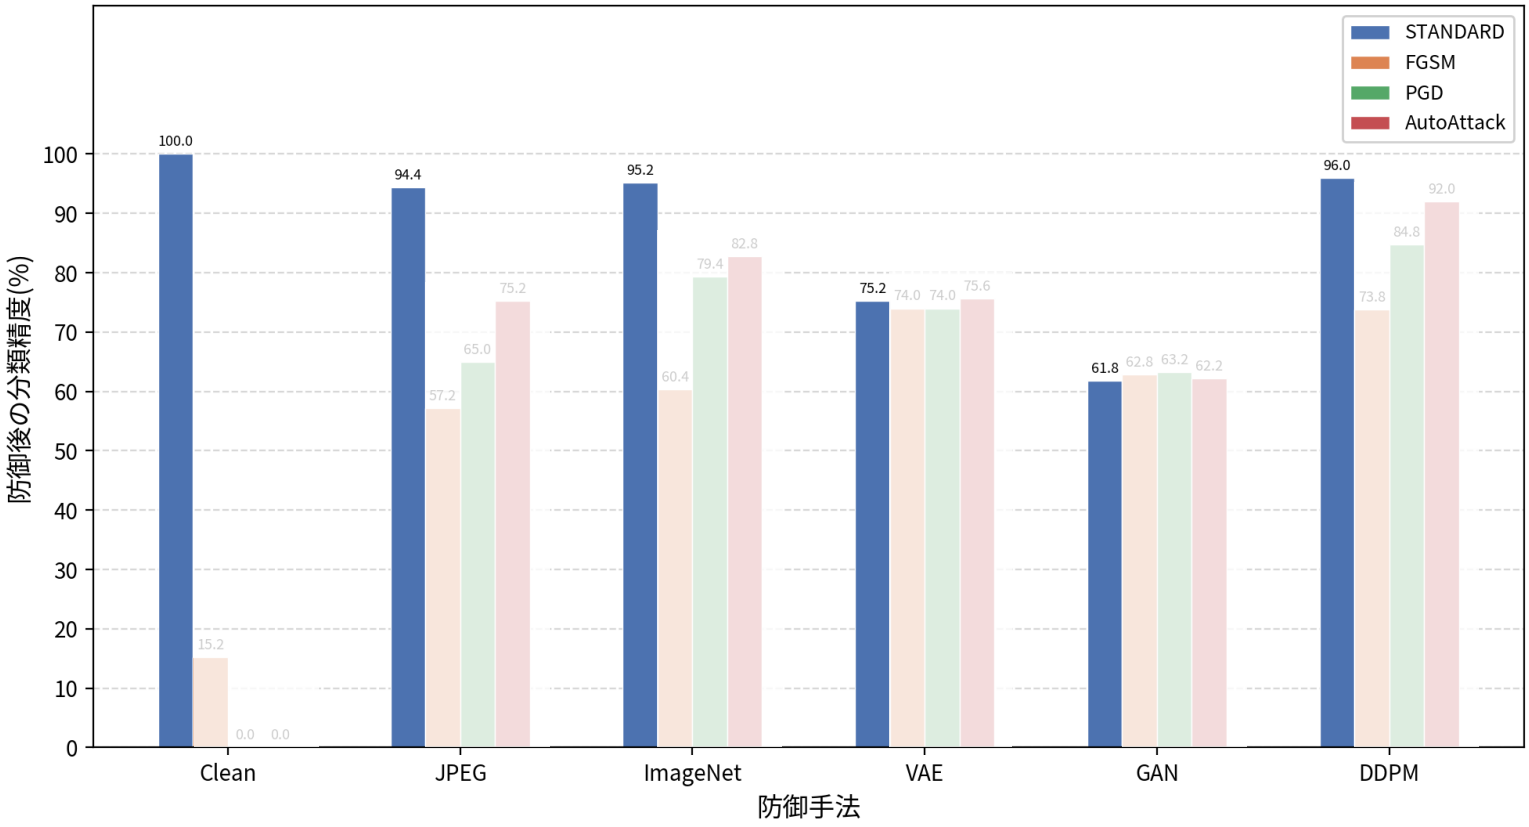
FGSMではVAEがDDPMを若干上回っているが、それ以外は
DDPMが最も防御性能が高い



摂動除去後の分類結果

- PCamデータセット

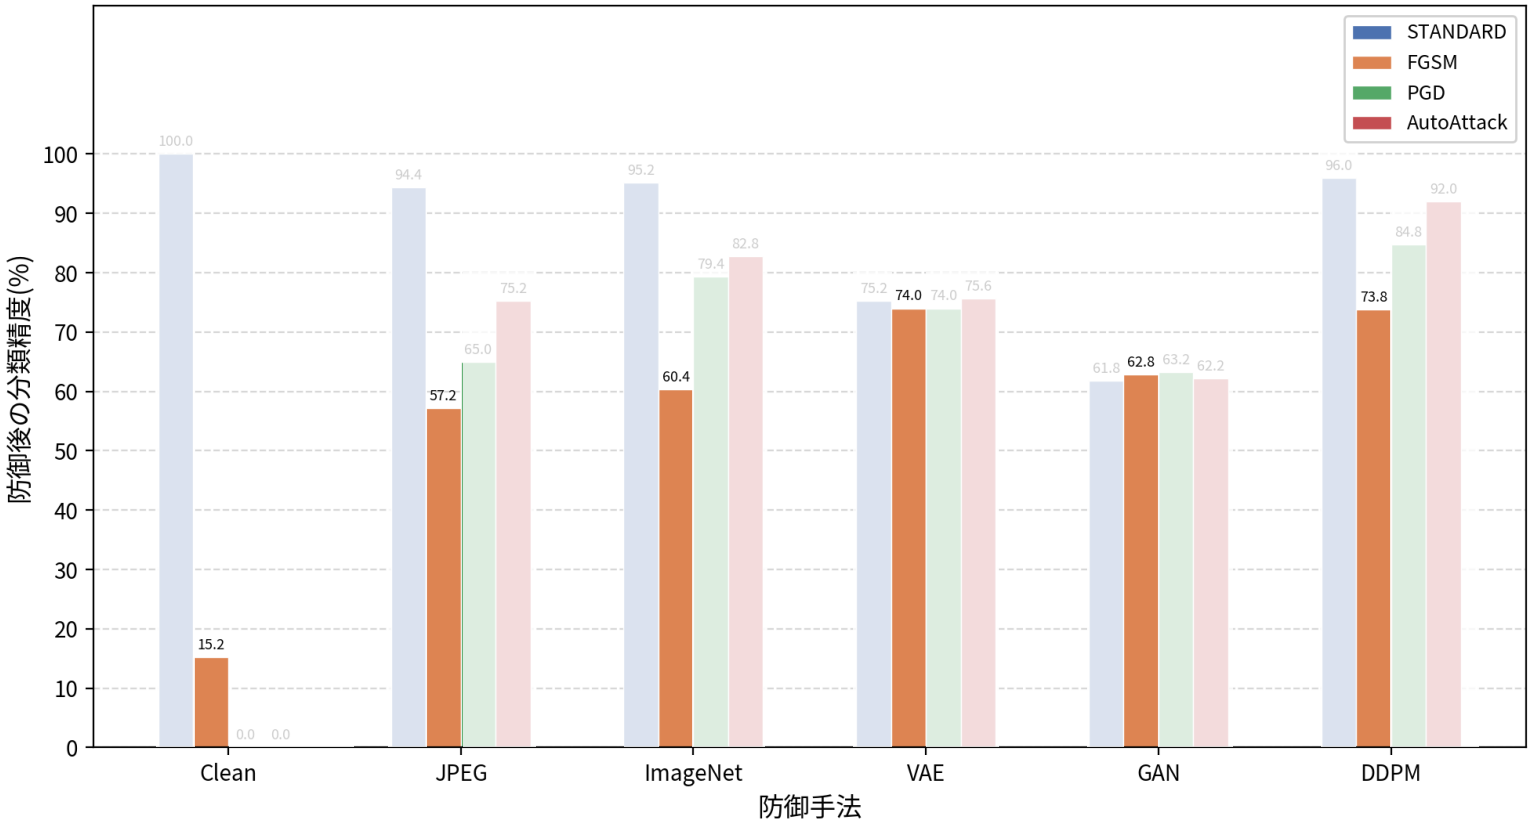
  FGSMではVAEがDDPMを若干上回っているが、それ以外は
  DDPMが最も防御性能が高い



摂動除去後の分類結果

- PCamデータセット

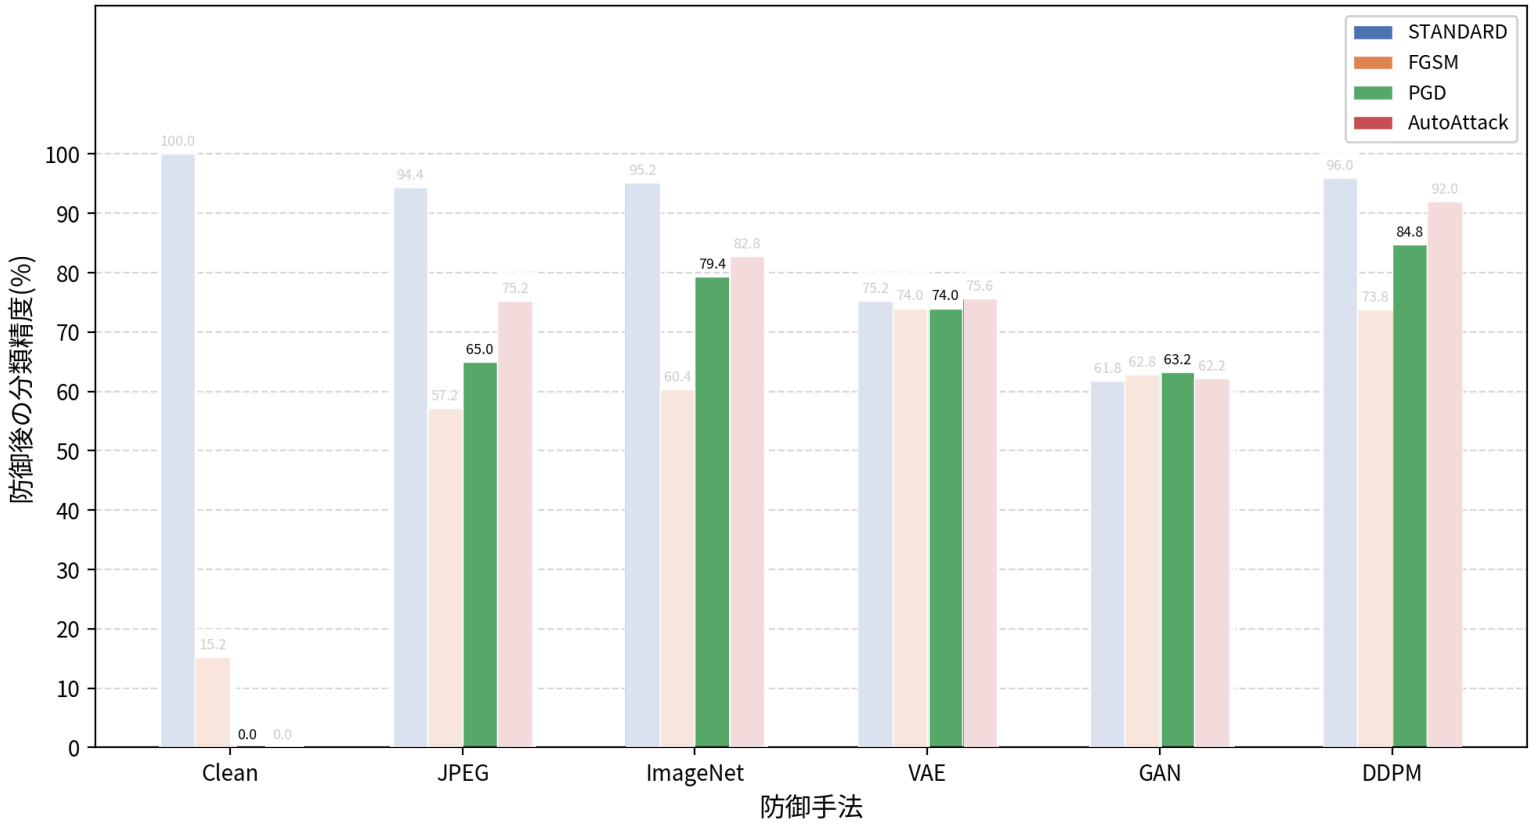
FGSMではVAEがDDPMを若干上回っているが、それ以外は
DDPMが最も防御性能が高い



摂動除去後の分類結果

- PCamデータセット

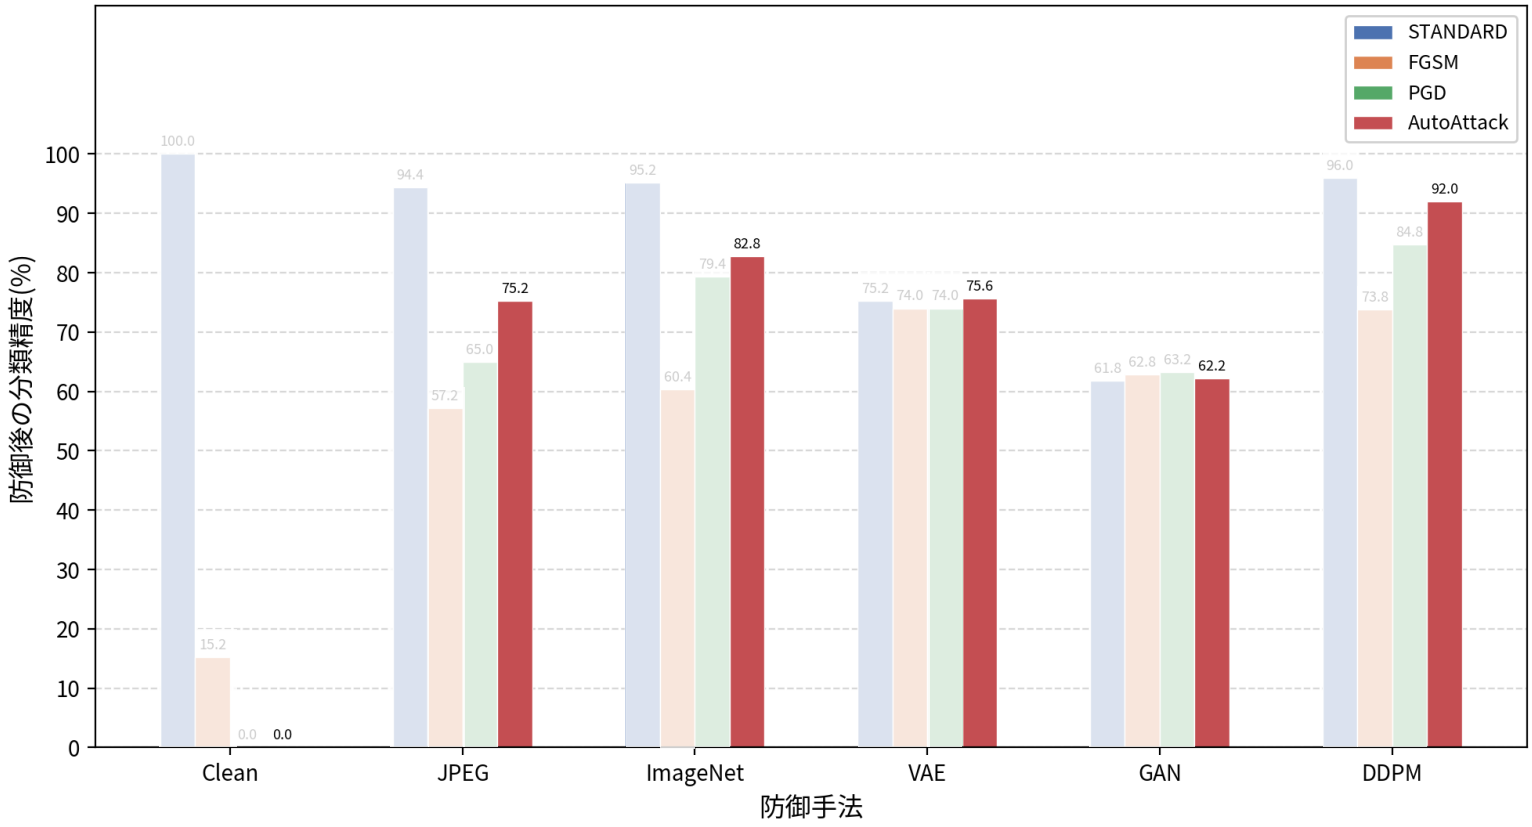
FGSMではVAEがDDPMを若干上回っているが、それ以外は
DDPMが最も防御性能が高い



摂動除去後の分類結果

- PCamデータセット

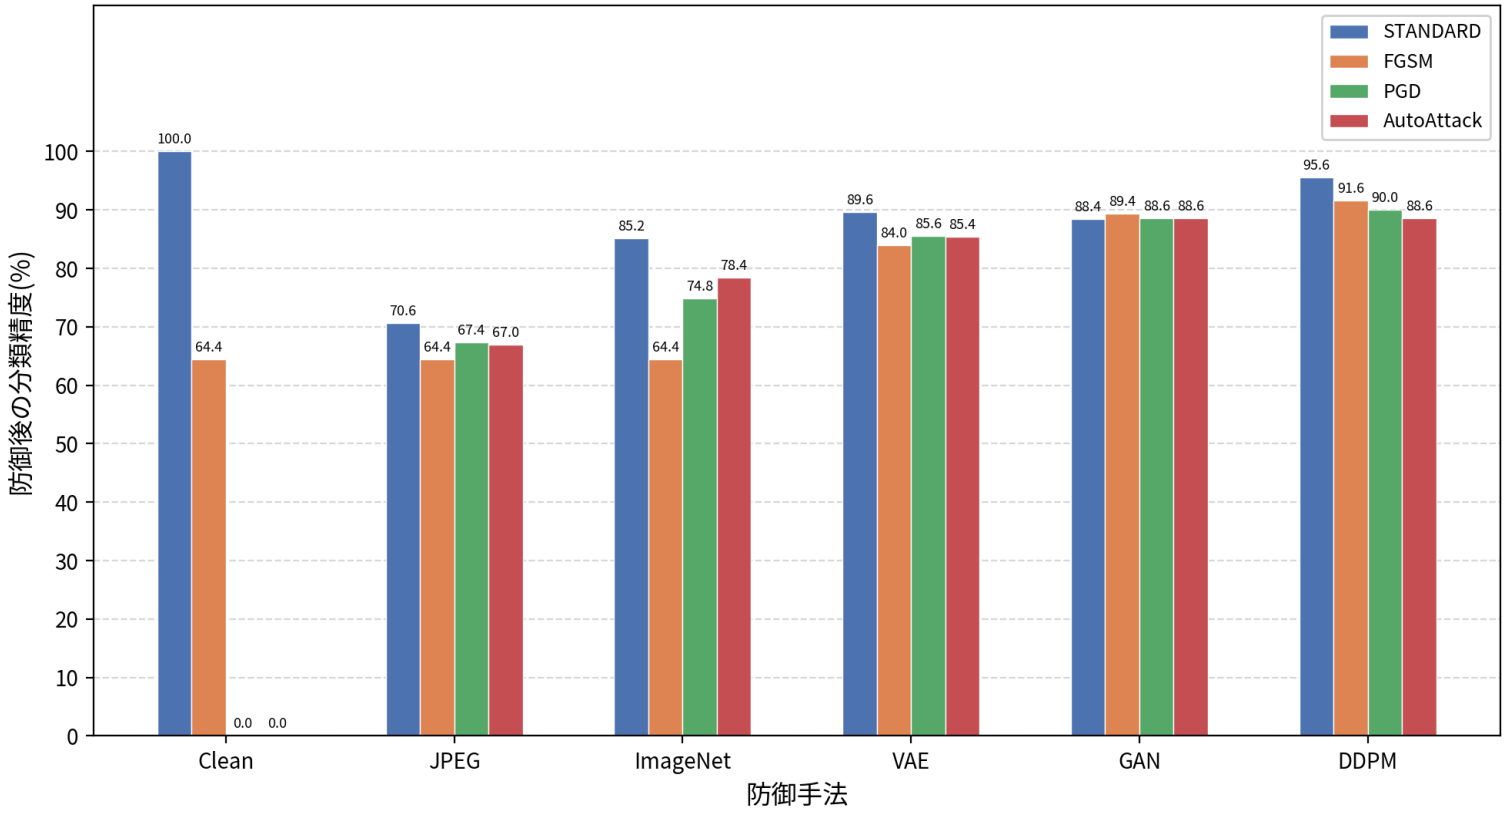
  FGSMではVAEがDDPMを若干上回っているが、それ以外は
  DDPMが最も防御性能が高い



摂動除去後の分類結果

- **ChestXrayデータセット**

AutoAttackではGANとDDPMが同じ精度でそれ以外はDDPMが最も防御性能が高い

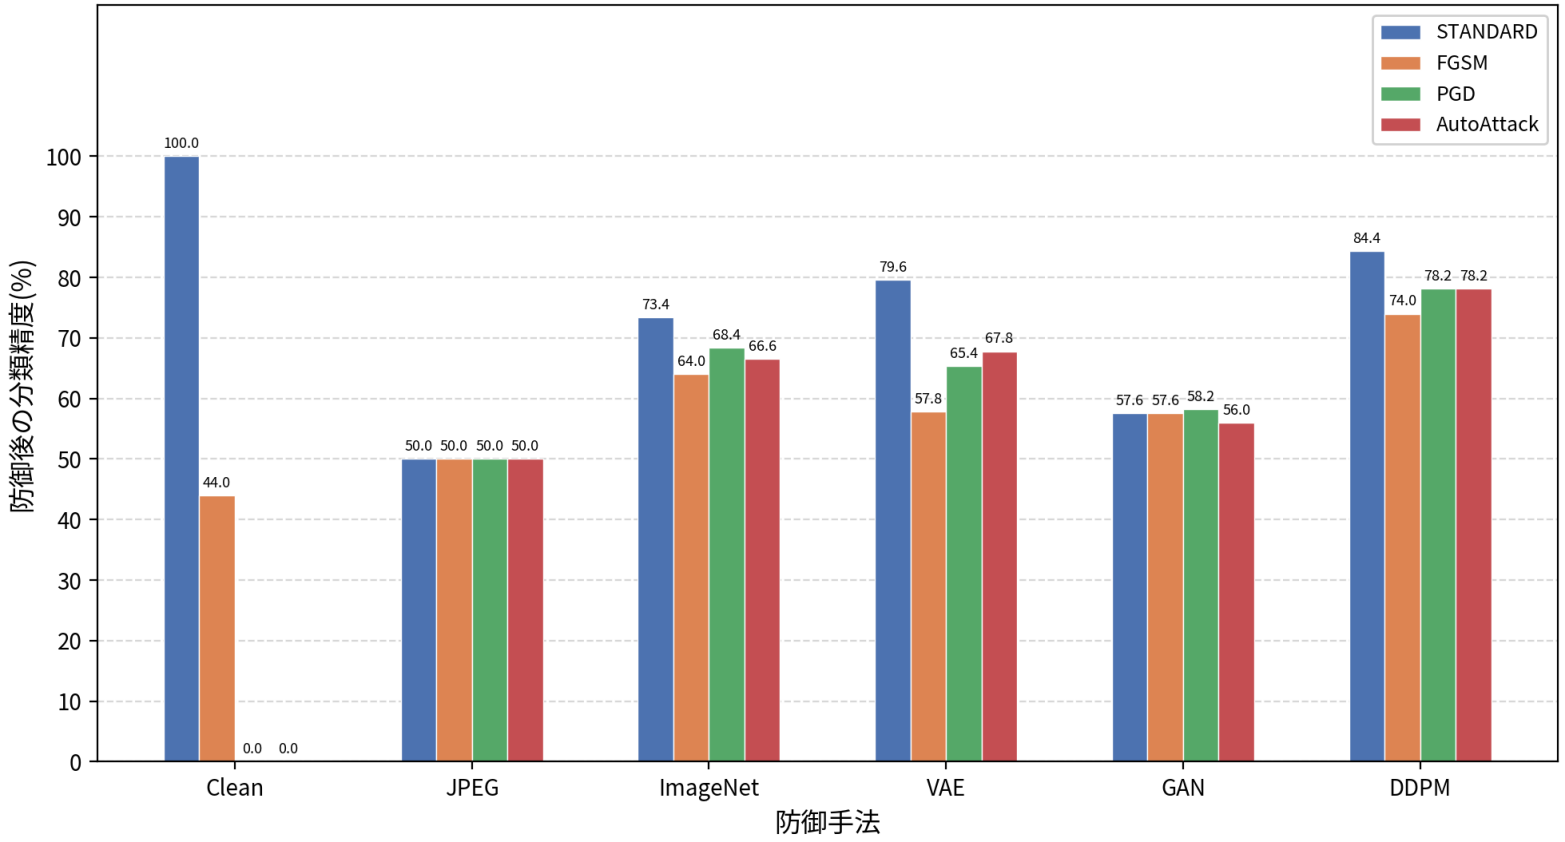


九州工業大学　竹本研究室　後藤

摂動除去後の分類結果

- **DermMelデータセット**

全ての攻撃手法においてDDPMの防御性能が最も高い



まとめ

- **DDPMが医用画像分類システムの敵対的防御に有用である**

- **DDPMが最も高い防御性能を示したのは多段階的なノイズ除去が、敵対的摂動に対して効果的に機能したためだと考えられる**

今後の課題

- DDPMには計算コストが高いという課題が残り、実用化には防御性能と計算コストのトレードオフを考慮する必要がある

- 逆拡散過程（特にノイズの加え方）についても検討する必要がある

補足資料